

TECNOLÓGICO NACIONAL DE MÉXICO.

INGENIERÍA EN SISTEMAS COMPUTACIONALES.



**TECNOLÓGICO
NACIONAL DE MÉXICO**



INTELIGENCIA ARTIFICIAL.

NOMBRE DEL ALUMNO:

**Cibrian Robles José Alonso.
Ontiveros Ramos Victoria Adahi.**

NOMBRE DEL DOCENTE: Manuel Alejandro Medrano Diaz.

TAREA 3.- ANÁLISIS DE DATOS Y RECONSTRUCCIÓN DE DATASET.

1. Introducción

El siguiente documento analizara algunos parámetros de calidad del agua subterránea que se nos proporciono en una tabla de datos provenientes directamente de la comisión nacional del agua CONAGUA, durante un periodo de 12 años, del 2012- 2024. El dataset tiene como propósito presentar un análisis de los datos, ya que contiene algunos datos faltantes.

De todas las columnas correspondientes al dataset, seleccionamos 10 variables, 8 numéricas y 2 categóricas que precisamente presentan datos faltantes con el objetivo de calcular estadísticas descriptivas, aplicar técnicas de imputación adecuadas a los respectivos datos, escalar las raibles para hacerlas consistentes en magnitud.

2. Variables Seleccionadas

- ALC_mg/L — Alcalinidad total (mg/L)
- CONDUCT_mS/cm — Conductividad eléctrica (mS/cm)
- SDT_mg/L — Sólidos Disueltos Totales (mg/L)
- FLUORUROS_mg/L — Concentración de fluoruros (mg/L)
- DUR_mg/L — Dureza total del agua (mg/L)
- COLI_FEC_NMP/100_mL — Coliformes fecales (NMP/100 mL)
- N_NO3_mg/L — Nitratos expresados como nitrógeno (mg/L)
- AS_TOT_mg/L — Arsénico total (mg/L)
- MN_TOT_mg/L — Manganeseo total (mg/L)
- FE_TOT_mg/L — Hierro total (mg/L)

Calidad Global: Verde/Amarillo/Rojo y CALIDAD_ALC clasificación de alcalinidad.

Nos dimos cuenta de que estas variables precisamente contaban con datos faltantes por medio de ejecutar `df.isnull().sum()`

2. Estadísticas Descriptivas

Medidas de Tendencia Central

Las medidas de tendencia central nos permiten resumir un conjunto o distribución de datos en un solo valor que represente el comportamiento más representativo de toda la distribución, se dividen en calcular la media, que es el promedio, la mediana, el valor que se encuentra en el centro, y la moda, utilizado en las variables categóricas.

Media: Se considera el centro de gravedad de los datos; sin embargo, es altamente sensible a los valores atípicos. Un solo valor extremo puede desplazar la media, haciendo que deje de ser representativa del resto del grupo.

Mediana: Es el valor que se ubica exactamente en el centro de los datos cuando estos están ordenados. Es una medida robusta, lo que significa que no se deja "engañar" por valores atípicos extremos, manteniendo una posición central fiel a la estructura de la muestra.

Moda: Es el valor o categoría que cuenta con la mayor frecuencia de aparición, para valores categóricos, la moda es la única medida de tendencia central aplicable para determinar la preferencia o tendencia del grupo.

Medidas de Dispersión

Varianza: Representa el promedio de las distancias al cuadrado entre cada dato individual y la media aritmética. Se elevan las diferencias al cuadrado por dos razones principales: para eliminar los valores negativos que anularían la sumatoria y para penalizar con mayor peso los errores grandes o valores muy alejados del centro.

Desviación Estándar: Raíz cuadrada de la varianza. Indica cuánto se alejan, en promedio, los puntos individuales respecto a la media. Cuanto mayor es su valor, más dispersos están los datos alrededor de la media. Un valor bajo indica que los datos están agrupados cerca de la media.

Tabla de Resultados

Estadísticas descriptivas para variables numéricas:				
	mean	median	var	std
ALC_mg/L	229.437670	211.808500	1.428993e+04	119.540509
CONDUCT_mS/cm	1040.948877	721.000000	1.246772e+06	1116.589518
SDT_mg/L	748.882831	484.825000	1.033051e+06	1016.391021
FLUORUROS_mg/L	1.042967	0.578400	2.465490e+00	1.570188
DUR_mg/L	329.653919	226.551000	1.326091e+05	364.155288
COLI_FEC_NMP/100_mL	177.711448	10.000000	5.028989e+06	2242.540846
N_NO3_mg/L	12.718302	2.043000	1.871600e+04	136.806434
AS_TOT_mg/L	0.018841	0.003461	2.633742e-03	0.051320
MN_TOT_mg/L	0.066962	0.002441	7.729365e-02	0.278017
FE_TOT_mg/L	0.185851	0.055455	6.095399e-01	0.780730


El análisis numérico revela que variables como la Conductividad y los Sólidos Disueltos Totales (SDT) presentan desviaciones estándar y varianzas sumamente elevadas en comparación con sus medias. En parámetros críticos de contaminación, como el Arsénico y los Coliformes Fecales, se observa una brecha considerable entre la media y la mediana; el hecho de que la media sea significativamente mayor indica que la distribución está sesgada por valores extremos. Esto nos puede sugerir el uso de mediana para imputación de datos faltantes, es mejor representar el centro al no verse afectada por los picos de contaminación del dataset.

Variables Categóricas

Estadísticas descriptivas para variables categóricas (Moda):	
	0
CALIDAD_ALC	Alta
CALIDAD_COLI_FEC	Buena calidad


4. Análisis Gráfico de la Distribución

Las siguientes gráficas muestran los histogramas de frecuencia de cada variable numérica antes del proceso de imputación. Las líneas punteadas indican la media (rojo) y la mediana (azul), permitiendo identificar visualmente el grado de asimetría en cada distribución.



Se puede observar que todas las variables presentan una distribución con sesgo positivo (cola hacia la derecha), lo cual es consistente con variables de calidad del agua donde la mayoría de los valores son bajos pero existen sitios con concentraciones muy elevadas. En todos los casos la mediana es menor que la media, confirmando este sesgo.

Los siguientes diagramas de caja (boxplots) permiten identificar la mediana, los cuartiles y los valores atípicos de forma más precisa



5. Análisis de Datos Faltantes

La presencia de datos faltantes puede tener diferentes causas como fallas en equipo, limitaciones de presupuesto en el muestreo o umbrales de detección en laboratorios, por eso se dice que nunca se debe eliminar un dato atípico a menos que se tenga certeza de porque ocurrió, en este preciso dataset no lo sabemos, y además la proporción de valores faltantes presenta una variabilidad significativa, yendo desde un mínimo del 1.8% en parámetros de medición rutinaria (como la Conductividad), hasta un 25.9% en análisis biológicos más complejos (como los Coliformes Fecales).

6. Técnicas de Imputación

Imputación por Mediana

La imputación estadística por mediana consiste en sustituir cada valor numérico faltante por el valor central de las observaciones disponibles en su respectiva columna. Esta técnica destaca por ser un método directo y altamente robusto; al priorizar la mediana sobre la media aritmética, se previene que los valores atípicos contaminen las estimaciones y sesguen la distribución. En este análisis, se aplicó específicamente a aquellas variables que presentaban un porcentaje de datos faltantes bajo (menor al 5%). La elección de esta medida central se justifica, por tanto, en su probada resistencia matemática frente a los valores extremos previamente identificados en el conjunto de datos.

Imputación por KNN (K-Vecinos Más Cercanos)

Para aquellas variables que presentan un índice de faltantes moderado (entre el 7% y el 11%), como los Fluoruros, Nitratos y el Arsénico y con el objetivo de evitar la deformación de la distribución original y prevenir la introducción de sesgos artificiales, se implementó una técnica de imputación algorítmica más sofisticada mediante K-Vecinos Más Cercanos (KNN).


Configurado con, este enfoque multivariable evalúa el contexto de cada observación para identificar los cinco registros más similares en función de las variables disponibles aprovechando las correlaciones subyacentes con parámetros como la conductividad, dureza y sólidos disueltos. Una vez localizados los vecinos, el algoritmo calcula y asigna un promedio ponderado para

predecir la concentración química faltante de manera precisa. Esto permite generar estimaciones más realistas que preservan la estructura y las relaciones entre las variables del dataset.

6.3 Imputación por Moda (Variables Categóricas)

Para el tratamiento de las variables categóricas, se implementó un algoritmo de imputación basado en la sustitución de los valores faltantes por la categoría más frecuente, es decir, la moda. Esta técnica representa la única medida de tendencia central matemáticamente viable para este tipo de información, ya que no existe una noción de promedio o mediana aplicable a categorías nominales u ordinales.

La comparación gráfica entre la distribución original, la imputada por mediana y la imputada por KNN se muestra a continuación:



Se puede observar que la imputación KNN conserva mejor la forma de la distribución original (histogramas más suaves), mientras que la imputación por mediana genera un pico más pronunciado en el valor central.

7. Técnicas de Escalamiento

Una vez concluida la fase de imputación, es necesario que los datos pasen por un proceso de escalamiento para garantizar su comparabilidad matemática. Esta etapa es crítica dado que las variables del dataset presentan magnitudes radicalmente dispares, oscilando desde

concentraciones de arsénico en el orden de microgramos (0.0001 mg/L) hasta niveles de coliformes fecales que alcanzan los 82,000 NMP/100 mL.

Normalización Min-Max


Este método transforma todos los valores a una escala delimitada entre 0 y 1, lo cual resulta útil cuando se conocen los límites naturales del fenómeno empírico o no se asume una distribución normal. Esta técnica preserva la forma de la distribución original, pero también tiene una vulnerabilidad significativa: su extrema sensibilidad a los valores atípicos. En el contexto de este dataset, la presencia de valores máximos extremos en variables como los coliformes fecales y los nitratos provoca que, al normalizar, la gran mayoría de las observaciones regulares queden drásticamente comprimidas en un rango minúsculo cercano a cero.

Estandarización (Z-score con Mediana)

A diferencia de la estandarización clásica, la sustitución de la media aritmética por la mediana confiere a este método una robustez superior frente a los valores atípicos. Esta técnica centra los datos alrededor del cero con una desviación estándar de 1, lo que permite interpretar cada registro en función de cuántas desviaciones estándar se aleja del centro exacto de la distribución. Su principal ventaja es que no acota las observaciones a un rango fijo predeterminado, en consecuencia, los valores atípicos reales no aplastan al resto de la muestra, sino que continúan siendo matemáticamente identificables, sin comprometer la integridad de la estructura general de los datos.

Tabla Comparativa de Escalamiento

Las distribuciones después del escalamiento se visualizan a continuación:



Conclusiones

El análisis realizado sobre los parámetros de calidad del agua subterránea permitió identificar que los datos no siguen un comportamiento homogéneo ni estable, es decir en este dataset podemos observar que los datos de CONAGUA nos revelan no se un fenómeno estadísticamente normal. presentan una alta variabilidad entre sitios de muestreo. La diferencia constante entre la media y la mediana en la mayoría de las variables evidencia distribuciones asimétricas, probablemente influenciada por factores o variables externas que desconocemos, aunque la mayor parte de los sitios presentan niveles aceptables, existe una concentración de puntos con contaminación aguda que distorsionan y elevan el comportamiento global de los datos. Esto se ve reflejado en algunas variables que concentran mayor cantidad de valores nulos.

Este tipo de situaciones donde se presenten valores nulos puede ser más común de lo que parece, es por ello que es importante aplicar técnicas de imputación adecuadas, ya que ignorar estos valores ausentes o tratarlos de manera indiscriminada puede distorsionar la interpretación estadística y afectar la calidad del análisis posterior, por ello la imputación basada en medidas de tendencia central resultó útil para conservar la estructura general de los datos, mientras que en variables categóricas la moda permitió mantener coherencia con el comportamiento más frecuente del conjunto.

Y una vez imputados, también tenemos que destacar el escalamiento de variables como una parte fundamental para hacer comparables parámetros que originalmente se encontraban en magnitudes muy distintas. Si este proceso se evita o no se toma en cuenta, los valores con rangos más altos desplazarían completamente a los más bajos y dominarían el análisis, reduciendo la capacidad de evaluar y analizar profundamente el comportamiento.

Finalmente podemos decir que no existe un único método universalmente mejor para todos los casos. La combinación más adecuada fue aquella que consideró la naturaleza de cada variable, su distribución, la presencia de valores atípicos y la cantidad de datos faltantes. Por ello, la estrategia híbrida nos permite conservar la mayor cantidad de información posible, ya que más que aplicar algoritmos de forma automática, un análisis de datos efectivo depende de seleccionar conscientemente las técnicas de imputación y escalamiento según el contexto y las características que se nos presente según el problema.